

Documentação Técnica e Análise de Probabilidades Condicionais

Análise Estrutural do Script 01_simula_dados.R

Engenharia de Dados & Epidemiologia

2026-06-08

Contents

1. Introdução e Filosofia do Banco de Dados	2
A intenção primária deste dataset é servir como base para um pipeline de geração de databooks automatizados para todas as variáveis, com estatísticas sumárias e visualizações pré-definidas, disponíveis neste código	2
2. Configurações Iniciais e Amostragem	2
3. Estrutura Sociodemográfica e Condicionais de Renda	2
4. Antropometria Materna	4
5. Assistência ao Pré-Natal	4
6. Morbidade Gestacional	5
7. Desfechos Neonatais e Impacto Vital	7
Imputação de Dados Ausentes	7
Automação via JSON e metadados	8
Exportação dos Dados para Databook Automatizado de TODAS AS VARIÁVEIS	9

1. Introdução e Filosofia do Banco de Dados

Este documento detalha a arquitetura de dados e as dependências probabilísticas injetadas no banco de dados perinatal simulado. A filosofia de construção deste banco fake afasta-se de distribuições puramente aleatórias e independentes. Em epidemiologia, os fatores determinantes sociais (como renda e contexto histórico) impactam diretamente as exposições clínicas e os desfechos de saúde do recém-nascido.

O script manipula a geração de dados para criar cadeias de dependência estocástica e restrições biológicas. O dataset final é gerado em duas versões:

Versão Rotulada: Preserva as strings amigáveis para leitura e análise direta (“Sim”, “Não”, “Cesárea”).

Versão Codificada: Converte dinamicamente textos em códigos numéricos pareados, utilizando um dicionário JSON canônico que serve como infraestrutura para a geração de um databook automático.

A intenção primária deste dataset é servir como base para um pipeline de geração de databooks automatizados para todas as variáveis, com estatísticas sumárias e visualizações pré-definidas, disponíveis neste código

2. Configurações Iniciais e Amostragem

Este bloco inicial garante a reprodutibilidade da simulação e define a janela amostral dividida entre dois anos históricos em três municípios brasileiros - **1997 e 2003**.

Variáveis:

n_total: total de observações do banco.

n_por_ano: número de observações por ano, garantindo equilíbrio temporal.

anos: vetor de anos para amostragem.

cidades: vetor de siglas dos municípios, representando os centros de coleta de dados.

```
set.seed(42)
suppressPackageStartupMessages({
  library(dplyr)
  library(tidyr)
  library(jsonlite)
})

# ---- 1. Parâmetros -----
n_total    <- 2000
n_por_ano  <- 1000
anos       <- c(1997, 2013)
cidades    <- c("SLZ", "PEL", "RP")
```

3. Estrutura Sociodemográfica e Condicionais de Renda

Nesta seção, o contexto econômico dita as vulnerabilidades sociais da gestante. Foram inseridos condicionais de probabilidade à renda familiar dado o estado civil da gestante.

Variáveis:

df: banco de dados inicial

id: identificador único para cada observação

maternidade: número de maternidades amostradas por cidade (A1, A2, A3, B1, B2, B3, C1, C2, C3)

idade_mae: idade da mãe simulada com distribuição normal, limitada em entre 18 e 45 anos, com média de 28 anos e desvio padrão de 6 anos

idade_mae_categoria: idade da mãe simulada com apresentação por categorias de idade baseadas em pontos de corte de idade

renda_mae_reais: renda da mãe simulada com distribuição normal logarítmica, por conta da assimetria típica de dados de renda, com parâmetros ajustados para refletir o contexto econômico de cada ano

salario_minimo: salário mínimo vigente em cada ano, utilizado como referência para categorizar

renda_mae_quintis_sm: categorização da renda da mãe em quintis de salário mínimo, refletindo a distribuição socioeconômica

mae_solteira: variável binária indicando se a mãe é solteira, com probabilidade condicionada à renda, simulando a maior vulnerabilidade social associada à baixa renda

```
# ---- 2. Estrutura base + sociodemográficas -----
df <- tibble(
  id      = 1:n_total,
  ano     = rep(anos, each = n_por_ano),
  cidade  = sample(cidades, n_total, replace = TRUE)
) |>
mutate(
  maternidade = case_when(
    cidade == "SLZ" ~ sample(c("A1", "A2", "A3"), n(), replace = TRUE),
    cidade == "PEL" ~ sample(c("B1", "B2", "B3"), n(), replace = TRUE),
    cidade == "RP"  ~ sample(c("C1", "C2", "C3"), n(), replace = TRUE)
  ),
  idade_mae = round(pmax(18, pmin(45, rnorm(n(), mean = 28, sd = 6)))),
  idade_mae_categoria = cut(
    idade_mae,
    breaks = c(0, 20, 30, 40, 100),
    labels = c("18-20", "21-30", "31-40", ">40"),
    include.lowest = TRUE
  ),
  renda_mae_reais = case_when(
    ano == 1997 ~ round(exp(rnorm(n(), mean = 6.5, sd = 0.8)), 2),
    ano == 2013 ~ round(exp(rnorm(n(), mean = 7.8, sd = 0.9)), 2)
  ),
  salario_minimo = case_when(ano == 1997 ~ 120, ano == 2013 ~ 678),
  renda_mae_quintis_sm = case_when(
    renda_mae_reais < salario_minimo ~ "< 1 SM",
    renda_mae_reais < salario_minimo * 2 ~ "1-2 SM",
    renda_mae_reais < salario_minimo * 3 ~ "2-3 SM",
    renda_mae_reais < salario_minimo * 5 ~ "3-5 SM",
    TRUE ~ "> 5 SM"
  ),
  mae_solteira = ifelse(
    renda_mae_reais < salario_minimo * 2,
    sample(c(TRUE, FALSE), n(), replace = TRUE, prob = c(0.45, 0.55)),
    sample(c(TRUE, FALSE), n(), replace = TRUE, prob = c(0.20, 0.80))
  )
)
```

```
) |>
select(-salario_minimo)
```

4. Antropometria Materna

Mapeia a composição corporal da gestante, aplicando uma correlação linear forçada entre o ganho de peso gestacional e o peso inicial.

Variáveis:

peso_mae_pre_gestacao_kg: peso da mãe antes da gestação, simulado com distribuição normal, limitada entre 45 kg e 120 kg, com média de 65 kg e desvio padrão de 12 kg. Variável contínua

peso_mae_categoria: categorização do peso pré-gestacional da mãe em “Baixo peso”, “Normal”, “Sobrepeso” e “Obesidade”, com base em pontos de corte típicos de IMC para gestantes. Variável categórica

```
# ---- 3. Antropometria materna -----
df <- df |>
mutate(
  peso_mae_pre_gestacao_kg = round(
    pmax(45, pmin(120, rnorm(n(), mean = 65, sd = 12))), 1
  ),
  peso_mae_pos_gestacao_kg = round(
    peso_mae_pre_gestacao_kg + rnorm(n(), mean = 12, sd = 4), 1
  ),
  peso_mae_categoria = cut(
    peso_mae_pre_gestacao_kg,
    breaks = c(0, 50, 65, 80, 200),
    labels = c("Baixo peso", "Normal", "Sobrepeso", "Obesidade"),
    include.lowest = TRUE
  )
)
```

5. Assistência ao Pré-Natal

Avalia o acesso ao serviço de saúde pública com base na interação entre economia e período do tempo. Há probabilidade condicional de **realizar o pré natal completo** dado o ano, e a renda da mãe em reais ser menor ou maior que um salário mínimo.

Variáveis:

prob_prenatal: probabilidade de realizar o pré-natal completo, calculada com base em regras condicionais que levam em conta o ano da gestação e a renda da mãe em relação ao salário mínimo vigente. Variável intermediária utilizada para simular a variável final. Pré natal completo = pelo menos 6 consultas de pré natal nas primeiras 12 semanas de gestação

prenatal_6_consultas_12sem: variável binária indicando se a mãe realizou o pré natal completo

```
# ---- 4. Pré-natal -----
df <- df |>
mutate(
  salario_minimo = case_when(ano == 1997 ~ 120, ano == 2013 ~ 678),
  prob_prenatal = case_when(
    ano == 1997 & renda_mae_reais < salario_minimo ~ 0.35,
    ano == 1997 & renda_mae_reais < salario_minimo * 3 ~ 0.55,
    ano == 1997 ~ 0.70,
  )
)
```

```

ano == 2013 & renda_mae_reais < salario_minimo ~ 0.60,
ano == 2013 & renda_mae_reais < salario_minimo * 3 ~ 0.80,
ano == 2013 ~ 0.90
),
prenatal_6_consultas_12sem =
  ifelse(runif(n()) < prob_prenatal, "Sim", "Não")
) |>
select(-prob_prenatal, -salario_minimo)

```

6. Morbidade Gestacional

Esta seção modela o risco biológico. As variáveis aqui foram modeladas como uma cadeia epidemiológica encadeada por pressupostos causais.

O IMC pré gestacional é condicionado ao peso da mãe pré gestacional; a probabilidade de diabetes gestacional é condicionada ao IMC pré gestacional; a probabilidade de hipertensão gestacional é condicionada à probabilidade de diabetes gestacional e ao IMC pré gestacional; a probabilidade de pré-eclâmpsia é condicionada à hipertensão pré gestacional.

```

# ---- 5. Comorbidades gestacionais -----
df <- df |>
mutate(
  imc_pre = peso_mae_pre_gestacao_kg / (1.62^2),
  prob_diabetes = case_when(
    idade_mae >= 35 & imc_pre >= 25 ~ 0.15,
    idade_mae >= 35 ~ 0.10,
    imc_pre >= 25 ~ 0.08,
    TRUE ~ 0.03
  ),
  diabetes_gestacional =
    ifelse(runif(n()) < prob_diabetes, "Sim", "Não"),
  prob_hipertensao = case_when(
    idade_mae >= 35 & imc_pre >= 25 ~ 0.12,
    idade_mae >= 35 ~ 0.08,
    imc_pre >= 25 &
      prenatal_6_consultas_12sem == "Não" ~ 0.10,
    imc_pre >= 25 ~ 0.05,
    prenatal_6_consultas_12sem == "Não" ~ 0.05,
    TRUE ~ 0.02
  ),
  hipertensao_gestacional =
    ifelse(runif(n()) < prob_hipertensao, "Sim", "Não"),
  prob_preeclampsia = case_when(
    hipertensao_gestacional == "Sim" & idade_mae >= 35 ~ 0.20,
    hipertensao_gestacional == "Sim" ~ 0.12,
    idade_mae >= 35 & imc_pre >= 25 ~ 0.05,
    TRUE ~ 0.02
  ),
  pre_eclampsia =
    ifelse(runif(n()) < prob_preeclampsia, "Sim", "Não"),
  eclampsia = ifelse(
    pre_eclampsia == "Sim" & runif(n()) < 0.05, "Sim", "Não"
  )
) |>

```

```
select(-imc_pre, -prob_diabetes, -prob_hipertensao, -prob_preeclampsia)
```

A complexidade e vias de parto foram modeladas nos seguintes pressupostos:

- Se a gestante tiver 2 ou mais comorbidades, a probabilidade de parto de alto risco é de 80%.
- Se a gestante tiver 1 comorbidade, a probabilidade de parto de alto risco é de 45%.
- Se a gestante tiver idade maior ou igual a 35 anos, a probabilidade de parto de alto risco é de 30%.
- Caso contrário, a probabilidade de parto de alto risco é de 15%.

A variável que delimita parto de alto risco foi tratada como variável dicotômica.

A probabilidade de parto cesariano foi modelada com base em múltiplas condições, refletindo a complexidade clínica e as decisões médicas associadas a cada cenário de risco:

- Se a gestante tiver eclâmpsia, a probabilidade de cesariana é de 95%.
- Se a gestante tiver pré-eclâmpsia, a probabilidade de cesariana é de 75%.
- Se a gestante tiver diabetes gestacional e hipertensão gestacional é de 60%.
- Se a gestante tiver parto de alto risco, a probabilidade de cesariana é de 50%.
- Se a gestante tiver idade maior ou igual a 40 anos, a probabilidade de cesariana é de 45%.
- Se a gestante tiver idade menor que 20 anos, a probabilidade de cesariana é de 40%.
- Caso contrário, a probabilidade de cesariana é de 25%.

```
# ---- 6. Parto -----
df <- df |>
mutate(
  n_comorbidades =
    (diabetes_gestacional == "Sim") +
    (hipertensao_gestacional == "Sim") +
    (pre_eclampsia == "Sim") +
    (eclampsia == "Sim"),
  prob_alto_risco = case_when(
    n_comorbidades >= 2 ~ 0.80,
    n_comorbidades == 1 ~ 0.45,
    idade_mae >= 35 ~ 0.30,
    TRUE ~ 0.15
  ),
  gravidade_parto = ifelse(
    runif(n()) < prob_alto_risco, "Alto risco", "Baixo risco"
  ),
  prob_cesariana = case_when(
    eclampsia == "Sim" ~ 0.95,
    pre_eclampsia == "Sim" ~ 0.75,
    diabetes_gestacional == "Sim" &
      hipertensao_gestacional == "Sim" ~ 0.60,
    gravidade_parto == "Alto risco" ~ 0.50,
    idade_mae >= 40 ~ 0.45,
    idade_mae < 20 ~ 0.40,
    TRUE ~ 0.25
  ),
  tipo_parto =
    ifelse(runif(n()) < prob_cesariana, "Cesárea", "Normal")
) |>
select(-n_comorbidades, -prob_alto_risco, -prob_cesariana)
```

7. Desfechos Neonatais e Impacto Vital

A seguir desfechos relacionados ao recém-nascido (RN):

O peso ao nascer em kg, em valores absolutos, é condicionada à presença de pré-eclâmpsia e eclâmpsia, o peso pré-gestacional da mãe.

A probabilidade de baixo peso ao nascer ($< 2,5$ kg) é condicionada ao peso ao nascer, à morbididades gestacionais, à gravidade do parto e ao tipo de parto.

```
# ---- 7. Desfechos neonatais -----
df <- df |>
mutate(
  peso_ao_nascer_kg = case_when(
    pre_eclampsia == "Sim" & eclampsia == "Sim" ~
      round(pmax(1.8, rnorm(n(), mean = 2.4, sd = 0.4)), 2),
    pre_eclampsia == "Sim" ~
      round(pmax(1.8, rnorm(n(), mean = 2.7, sd = 0.5)), 2),
    diabetes_gestacional == "Sim" ~
      round(pmax(2.0, rnorm(n(), mean = 3.5, sd = 0.6)), 2),
    peso_mae_pre_gestacao_kg < 50 ~
      round(pmax(1.8, rnorm(n(), mean = 2.6, sd = 0.5)), 2),
    peso_mae_pre_gestacao_kg >= 80 ~
      round(pmin(4.5, rnorm(n(), mean = 3.6, sd = 0.7)), 2),
    TRUE ~
      round(pmax(1.8, pmin(4.5, rnorm(n(), mean = 3.2, sd = 0.6))), 2)
  ),
  baixo_peso_ao_nascer =
    ifelse(peso_ao_nascer_kg < 2.5, "Sim", "Não"),
  prob_complicacoes = case_when(
    peso_ao_nascer_kg < 2.0 & pre_eclampsia == "Sim" ~ 0.80,
    peso_ao_nascer_kg < 2.0 ~ 0.60,
    pre_eclampsia == "Sim" ~ 0.45,
    diabetes_gestacional == "Sim" ~ 0.35,
    gravidade_parto == "Alto risco" ~ 0.30,
    tipo_parto == "Cesárea" &
      gravidade_parto == "Alto risco" ~ 0.25,
    TRUE ~ 0.08
  ),
  complicacoes_neonatais =
    ifelse(runif(n()) < prob_complicacoes, "Sim", "Não"),
  prob_obito = case_when(
    peso_ao_nascer_kg < 1.5 ~ 0.15,
    peso_ao_nascer_kg < 2.0 &
      complicacoes_neonatais == "Sim" ~ 0.08,
    complicacoes_neonatais == "Sim" ~ 0.03,
    TRUE ~ 0.001
  ),
  obito_neonatal_precoce =
    ifelse(runif(n()) < prob_obito, "Sim", "Não")
) |>
select(-prob_complicacoes, -prob_obito)
```

Imputação de Dados Ausentes

Foram imputados missings MCAR para aproximar o banco ao máximo da realidade.

```
# ---- 8. Missings (MCAR) -----
introduzir_missings <- function(df, col, pct = 0.02) {
  n_miss <- round(nrow(df) * pct)
  idx <- sample(seq_len(nrow(df)), size = n_miss, replace = FALSE)
  df[[col]][idx] <- NA
  df
}

df <- df |>
  introduzir_missings("renda_mae_reais",      0.04) |>
  introduzir_missings("peso_mae_pre_gestacao_kg", 0.03) |>
  introduzir_missings("diabetes_gestacional",  0.02) |>
  introduzir_missings("hipertensao_gestacional", 0.02) |>
  introduzir_missings("pre_eclampsia",         0.02) |>
  introduzir_missings("prenatal_6_consultas_12sem", 0.03) |>
  introduzir_missings("peso_ao_nascer_kg",     0.02) |>
  introduzir_missings("complicacoes_neonatais", 0.02)
```

Automação via JSON e metadados

O banco final é exportado em duas versões: uma versão rotulada, com strings amigáveis para leitura e análise direta, e uma versão codificada, onde os textos são convertidos dinamicamente em códigos numéricos pareados. O dicionário JSON canônico serve como infraestrutura para a geração de um databook automático, facilitando a documentação e a compreensão do dataset.

Para fins didáticos, esta parte não foi rodada neste script, mas o código abaixo exemplifica como a recodificação é realizada utilizando o dicionário JSON.

```
# ---- 10. Recodificação número <- rótulo, guiada pelo JSON canônico -----
dic <- fromJSON("dicionario/dicionario.json", simplifyVector = FALSE)

recodificar <- function(df, dic) {
  for (v in dic$variaveis) {
    if (!identical(v$tipo, "categorica")) next
    if (is.null(v$valores) || length(v$valores) == 0) next
    col <- df[[v$nome]]
    if (is.numeric(col)) next # já codificada (ex.: ano)

    # rótulo presente nos dados crus: rotulo_origem, ou rotulo se ausente
    rot <- vapply(v$valores, function(x) {
      if (!is.null(x$rotulo_origem)) x$rotulo_origem else x$rotulo
    }, character(1))
    cod <- vapply(v$valores, function(x) as.numeric(x$codigo), numeric(1))

    mapa <- setNames(cod, rot)
    df[[v$nome]] <- unname(mapa[as.character(col)])
  }
  df
}

df_codificado <- recodificar(df_rotulado, dic)
saveRDS(df_codificado, "data/simulado/coorte_codificada.rds")
write.csv(df_codificado, "data/simulado/coorte_codificada.csv",
  row.names = FALSE, fileEncoding = "UTF-8")
```


Exportação dos Dados para Databook Automatizado de TODAS AS VAR- IÁVEIS